

Expansao RAG

38 Subtipos Tumoriais

1.971

Registros
Totais

38

Subtipos
Tumoriais

Base de Conhecimento Oncologica de Precisao

1.900 casos clinicos + 71 documentos scientificos

1. Resumo Executivo

Este documento relata a expansao da base de conhecimento RAG (Retrieval-Augmented Generation) do DIMHEX AI Doctor da versao 3.0 para a versao 4.0, cobrindo a transicao de 11 para 38 subtipos tumorais. A base de conhecimento passou de 585 para 1.971 registros no ChromaDB, representando um crescimento de 237% na cobertura oncológica. O repovoamento foi concluido em 23.3 segundos, gerando 1.900 casos clinicos sinteticos com vetores realistas de biomarcadores distribuidos uniformemente entre os 38 subtipos, alem de 58 documentos cientificos validados e 13 protocolos terapeuticos NCCN/ESMO atualizados.

A expansao incorpora cânceres de mama (TNBC, HER2+, HR+ Luminal), prostata (hormossensível e castracao-resistente), pancreas (PDAC e neuroendocrino), sistema nervoso central (glioblastoma, astrocitoma IDH-mutante, meduloblastoma), figado (HCC), malignidades hematologicas (DLBCL, linfoma folicular, LLC, LMA, LPA), tumores osseos e medulares (osteossarcoma, sarcoma de Ewing, mieloma multiplo, MDS), trato gastrointestinal (colorretal MSI-H, gastrico HER2+, esofago), pele (melanoma BRAF e cutaneo), geniturinario (renal celular, bexiga urotelial), alem de cancer cervical HPV, tireoide e mesotelioma pleural. Esta cobertura abrange os cânceres com maiores numeros de incidencia global e inclui desde subtipos com maiores chances de regressao ate os mais complexos e letais.

Metrica	v3.0	v4.0	Crescimento
Subtipos Tumorais	11	38	+245%
Casos Clinicos	550	1.900	+245%
Documentos Cientificos	31	58	+87%
Protocolos NCCN/ESMO	4	13	+225%
Total de Registros	585	1.971	+237%
Tempo de Povoamento	~45s	23.3s	-48%

Tabela 1: Comparacao entre as versoes v3.0 e v4.0 do RAG DIMHEX.

2. Comparacao Visual da Expansao




Figura 1: Evolucao dos registros RAG de v3.0 para v4.0.

A transicao de v3.0 para v4.0 representou um salto quantitativo e qualitativo significativo na capacidade do sistema. O numero de casos clinicos triplicou, passando de 550 para 1.900, garantindo uma distribuicao uniforme de 50 casos por subtipo tumoral. Os documentos de conhecimento cientifico quase dobraram, passando de 31 para 58, incorporando literatura recente sobre imunoterapia, terapias-alvo, anticorpos biespecificos, CAR-T, ADCs (antibody-drug conjugates) e biomarcadores emergentes para os 27 novos subtipos adicionados.

Os protocolos terapeuticos saltaram de 4 para 13, cobrindo diretrizes NCCN e ESMO para pulmao, mama (TNBC, HER2+, HR+), prostata, SNC, HCC, colorretal, gastrico/esofago, melanoma, rinha/bexiga e hematologicas. Cada protocolo inclui algoritmos de tratamento de primeira linha, opcoes de segunda/terceira linha, biomarcadores mandatorios para testagem, e recomendacoes de monitoramento com ctDNA. A reducao do tempo de povoamento de 45s para 23.3s reflete otimizacoes na geracao de vetores gaussianos e no pipeline de indexacao.

3. Distribuicao dos 38 Subtipos Tumerais




Figura 2: Distribuicao dos 38 subtipos por categoria oncológica.

A distribuicao dos 38 subtipos foi projetada para cobrir as principais categorias oncologicas com prevalencia clinica significativa. Os 8 canceres raros originais (sinonasal, biliar, adenoide cistico, amigdal, trompa de falopio, apendicular, paratireoide e ampular) foram mantidos como base de conhecimento diferenciada. Os 27 novos subtipos foram selecionados com base em incidencia global, complexidade terapeutica e disponibilidade de dados clinicos validados. Cada subtipo possui um perfil de biomarcadores distinto (ctDNA, CTC, TMB, PD-L1, TILs) calibrado com base em dados da literatura para gerar casos sinteticos realistas com variabilidade gaussiana.

Subtipo (ID)	Nome Clinico	Categoria	Casos
CANCER_SEIOS_FACE	Cancer Sinonasal	Raro	8
CANCER_DUCTO_BILIAR	Colangiocarcinoma	Raro	8
CARCINOMA_ADENOIDE_CISTICO	Adenoide Cistico	Raro	8
CANCER_AMIGDALA	Cancer de Amigdal	Raro	8
CANCER_TROMPA_FALOPIO	Trompa de Falopio	Raro	8
CANCER_APPENDICE	Cancer Apendicular	Raro	8
CANCER_PARATIREOIDE	Cancer Paratireoide	Raro	8
CANCER_AMPULAR	Cancer Ampular	Raro	8
NSCLC_KRAS_G12C	NSCLC KRAS-G12C	Pulmao	11
NSCLC_EGFR_MUTADO	NSCLC EGFR	Pulmao	11
TRIPLO_NEGATIVO_MAMARIO	Mama Triplo Negativo	Mama	12
MAMA_HER2_POSITIVO	Mama HER2+	Mama	12
MAMA_HR_POSITIVO_LUMINAL	Mama HR+ Luminal	Mama	12
PROSTATA_HORMOSSENSIVEL	Prostata Hormossensivel	Prostata	13
PROSTATA_CASTRACAO_RESISTENTE	Prostata CRPC	Prostata	13
PANCREAS_PDAC	Pancreas PDAC	Pancreas	14
PANCREAS_NEUROENDOCRINO	Pancreas NET	Pancreas	14
CEREBRO_GBM	Glioblastoma	SNC	15
CEREBRO_ASTROCITOMA_IDH	Astrocitoma IDH	SNC	15
CEREBRO_MEDULOBLASTOMA	Meduloblastoma	SNC	15
FIGADO_HCC	Hepatocarcinoma	Figado	16
SANGUE_LINFOMA_DLBCL	Linfoma DLBCL	Hematologico	17
SANGUE_LINFOMA_FOLICULAR	Linfoma Folicular	Hematologico	17
SANGUE_MIELOMA_MULTIPLO	Mieloma Multiplo	Medular	18
SANGUE_LEUCEMIA_MIELOIDE_AGLA	LMA	Hematologico	17
MEDULAR_MDS	Sindrome Mielodisplasica	Medular	18

Subtipo (ID)	Nome Clinico	Categoria	Casos
GI_COLORRETAL_MSI_H	Colorretal MSI-H	GI	19
GI_GASTRICO_HER2	Gastrico HER2+	GI	19
GI_ESOFGO	Cancer de Esofago	GI	19
PELE_MELANOMA_BRAF	Melanoma BRAF	Pele	20
PELE_MELANOMA_CUTANEO	Melanoma Cutaneo	Pele	20
GU_RENAL_CELULAR	Carcinoma Renal	GU	21
GU_BEXIGA_UROTELIAL	Bexiga Urotelial	GU	21
GINECOLOGICO_CERVICAL_HPV	Cancer Cervical HPV	Ginecologico	22
ENDOCRINO_TIREOIDE	Cancer de Tireoide	Endocrino	23
PLEURAL_MESOTELIOMA	Mesotelioma Pleural	Pleural	24
SANGUE_LEUCEMIA_AGLA_PROMIELOCITICA	LPA	Hematologico	17

Tabela 2: Lista completa dos 38 subtipos tumorais com 50 casos sinteticos cada.

4. Arquitetura do RAG v4.0

O RAG (Retrieval-Augmented Generation) do DIMHEX utiliza duas colecoes distintas no ChromaDB, cada uma otimizada para um tipo especifico de busca. A primeira colecao, "ai_doctor_tumores", armazena 1.900 casos clinicos sinteticos com vetores de 5 dimensoes de biomarcadores (ctDNA, CTC, TMB, PD-L1, TILs), permitindo busca por similaridade vetorial para encontrar casos analogos ao paciente em avaliacao. Cada caso inclui metadados como subtipo tumoral, estadio, performance status ECOG, linha de tratamento e decisao do comite de tumores.

A segunda colecao, "dimhex_conhecimento", armazena 71 documentos com embeddings semanticos de 64 dimensoes, incluindo 58 artigos cientificos de literatura oncológica e 13 protocolos terapeuticos NCCN/ESMO. Os embeddings sao gerados por um sistema hibrido que combina hash-based term weighting com ponderacao por relevancia clinica, cobrindo mais de 200 termos-chave do dominio oncológico incluindo biomarcadores (ctDNA, PD-L1, TMB, HER2, BRCA, FGFR2, IDH1, ALK, NTRK, MSI-H), terapias (pembrolizumab, osimertinib, trastuzumab, car-t, ADCs), e marcadores de evidencia (overall survival, hazard ratio, phase 3, randomized). Esta abordagem permite buscas semanticas robustas sem dependencia de modelos de linguagem externos, mantendo o sistema totalmente auto-contido.

5. Protocolos Terapeuticos Indexados

Diretriz	Biomarcadores Chave	Cobertura
NCCN NSCLC v4.2025	KRAS, EGFR, ALK, BRAF, RET, MET, NTRK, PD-L1	11 subtipos
NCCN Mama TNBC v3.2025	BRCA, PD-L1, TILs, TMB, ctDNA, HRD	TNBC
NCCN BTC v2.2025	FGFR2, IDH1, HER2, MSI, TMB, ctDNA	Biliar/Ampular
ESMO Canceres Raros 2025	HPV, PD-L1, BRCA, CA125, FGFR2	8 raros
NCCN Mama HER2+/HR+ v3.2025	HER2, ER, PR, PIK3CA, ESR1, BRCA	Mama
NCCN Prostata v2.2025	PSA, AR-V7, PSMA, BRCA, ctDNA, TP53	Prostata
NCCN SNC v2.2025	MGMT, IDH1, TMB, PD-L1, TP53, BRAF	Cerebral
NCCN HCC v2.2025	AFP, ctDNA, PD-L1, TMB, TILs, HBsAg	Figado
NCCN Colorretal v1.2025	MSI, KRAS, NRAS, BRAF, HER2, NTRK, ctDNA	GI
NCCN Gastrico/Esofago v1.2025	HER2, CLDN18.2, PD-L1, MSI, ctDNA	GI
NCCN Melanoma v2.2025	BRAF, NRAS, TMB, PD-L1, TILs, ctDNA, LDH	Pele
NCCN RCC/Bexiga v2.2025	VHL, PD-L1, FGFR3, TMB, ctDNA, NTRK	GU
ESMO Hematologicas 2025	CD20, BCMA, FLT3, IDH1, TP53, SF3B1	Hematologico

Tabela 3: Protocolos terapeuticos NCCN/ESMO indexados no RAG v4.0.

Os 13 protocolos terapeuticos cobrem as principais diretrizes oncologicas internacionais, incluindo recomendacoes de primeira linha, opcoes de resgate, criterios de elegibilidade para imunoterapia baseados em PD-L1 e TMB, terapias-alvo para alteracoes moleculares especificas (FGFR2, IDH1, BRAF, NTRK, ALK, RET, MET, KRAS G12C), e monitoramento de doenca minima residual via ctDNA. Cada protocolo foi indexado com score de relevancia classificado como "critico" pelo sistema de scoring DIMHEX, garantindo priorizacao nas buscas semanticas. A cobertura de biomarcadores ultrapassa 50 marcadores distintos, permitindo ao sistema de IA identificar opcoes terapeuticas personalizadas com base no perfil molecular de cada paciente.

6. Protocolo de Aprendizagem Continua

O scheduler v3.0 opera com 5 jobs configurados para aprendizado continuo. O job principal executa o ciclo completo DIMHEX a cada 4 horas (240 minutos), englobando as 7 fases do protocolo: COLETAR (pesquisa em PubMed, ClinicalTrials.gov e Google Scholar), AVALIAR (scoring bayesiano de relevancia clinica), FILTRAR (limiar minimo de 0.25), SABEDORIA (síntese e geracao de hipoteses via sistema Fênix), INTEGRAR (indexacao no ChromaDB), ANALISAR (geracao de insights acionaveis) e REPORTAR (consolidacao em relatorio). Com a cobertura expandida de 38 subtipos, cada ciclo de pesquisa agora consulta termos especificos para todos os subtipos, ampliando significativamente a superficie de captura de evidencias cientificas recentes.

O job de auto-povoamento RAG executa diariamente, gerando 2 novos casos sinteticos por subtipo (76 casos/dia = 2 x 38 subtipos). Este crescimento organico garante que a base de casos analogos se expande continuamente, melhorando a precisao das buscas por similaridade ao longo do tempo. O job de manutencao da memoria Senciencia executa compactacao de memorias episodicas (limite de 200) e geracao de sabedoria profunda, identificando padroes multi-ciclo. O health check a cada 10 minutos monitora a integridade do ChromaDB e dos arquivos de memoria persistente, emitindo alertas automaticamente se alguma anomalia for detectada.

Job	Intervalo	Funcao	Output/Dia
DIMHEX Ciclo Completo	4 horas	Pesquisa + Scoring + Sabedoria + Indexacao	N/A
Auto-Povoamento RAG	24 horas	Geracao de casos sinteticos	+76 casos
Manutencao Memoria	24 horas	Compactacao + sabedoria profunda	N/A
Relatorio Diario	24 horas	Consolidacao para dashboard	1 JSON
Health Check	10 minutos	Integridade ChromaDB + memoria	N/A

Tabela 4: Jobs do protocolo de aprendizagem continua v4.0.